

Class 2: Learning from Biosignal

Introduction

Biosignals \Rightarrow ข้อมูลทางการแพทย์ที่มีความสำคัญในการช่วยแพทย์วินิจฉัยโรค มีชื่อเรียกแตกต่างกันออกไปตามอวัยวะในร่างกาย เช่น คลื่นไฟฟ้าสมอง, คลื่นไฟฟ้าหัวใจ ในปัจจุบันสัญญาณเหล่านี้ จะถูกวินิจฉัยและอ่านโดยคุณหมอ ซึ่งมีความล่าช้าถ้าหากมีปริมาณคนไข้มาก จึงนำ AI+ML มาช่วยวินิจฉัยขณะคนไข้อยู่ที่บ้านได้

\Rightarrow แบบจำลองการเรียนรู้เชิงลึกสำหรับวิเคราะห์ประสิทธิภาพการนอน ด้วยคลื่นไฟฟ้าสมอง และเทคนิคที่นำไปต่อยอด

\Rightarrow sleep stage scoring การวิเคราะห์การนอนผ่านการวัดคลื่นไฟฟ้าจากส่วนต่างๆของร่างกาย ทำเมื่อมีปัญหาด้านการนอน เช่น นอนหลับไม่สนิท, หายใจขณะหลับจากการอุดกั้น

- ☐ ลักษณะของข้อมูลที่ถูกใช้ในการวัดประสิทธิภาพการนอน
- ☐ วิธีการเตรียมข้อมูลให้อยู่ในรูปแบบที่สามารถนำไปสร้างแบบจำลองได้
- ☐ การสร้าง DL model เบื้องต้น หรือ 1D Convolutional Neural Networks สำหรับวิเคราะห์การนอน
- ☐ การวัดผลและประเมินประสิทธิภาพแบบจำลอง
- ☐ การต่อยอดเพื่อนำแบบจำลองไปใช้งานจริง

การวิเคราะห์คลื่นสัญญาณจากร่างกายคน (Biosignal Analysis)

- ☒ Preprocessing \Rightarrow Remove noise or artifacts from signals

Noise อาจเกิดจากเวลาวัดสัญญาณจากร่างกายคน ติดอุปกรณ์ไม่ตรงจุด เพื่อให้ข้อมูลสะอาดพร้อมสำหรับการ train model ถ้าหากยังมี noise ในข้อมูล โมเดลอาจเรียนรู้แพทเทิร์นที่ผิดๆหรือสิ่งแปลกปลอมในข้อมูลที่เราไม่ต้องการ

- ☒ Feature extraction

\Rightarrow Derive feature that are meaningful มักจะสกัดเฉพาะลักษณะเด่นที่มีความหมายหรือรูปแบบตรงกับอาการของคนไข้

\Rightarrow Hand-engineered ต้องอาศัยผู้เชี่ยวชาญที่ทราบแพทเทิร์นหรือการในแต่ละโรค

- ☐ Model construction

\Rightarrow เอาคุณลักษณะเด่นที่สกัดได้ไปสร้างแบบจำลอง

\Rightarrow input is extraction features and Output is labels or innovations

ขั้นตอนที่ 1 และ 2 เป็นขั้นตอนที่แตกต่างออกไปตามการใช้งาน (Application-Specific) ประเภทของคลื่นสัญญาณ เป็นไปตามอาการของโรคที่เราสนใจ เช่น เวลาที่เราคิด เวลาที่เรานอน ทุกการกระทำ คลื่นสัญญาณในสมองมีแพทเทิร์นที่ต่างกัน สิ่งที่ต้องโฟกัสก็คือ **จะเป็นไปได้หรือไม่ ที่ Model จะสามารถเรียนรู้และ detect pattern ได้ทุกรูปแบบทุก biosignals \Rightarrow ยังไม่มีใครทำได้** ดังนั้น เพื่อพยายามลดกระบวนการ 1 และ 2 จึงนำเทคนิคนี้เข้ามาใช้

- ☐ Deep Learning \Rightarrow ใช้ได้กับสัญญาณลักษณะอาการหรือโรคเดียวกัน แม้จะมีข้อมูลคนไข้ที่มีลักษณะแตกต่างกัน โมเดลสามารถเรียนรู้จากตัวอย่างที่หลากหลายได้

\Rightarrow ใช้ multilayer to convert inputs from biosignals into ตัวเลขที่มีความหมายสอดคล้องกับอาการต่างๆที่คนไข้เป็น

Sleep Stage Scoring

\Rightarrow เป็นการวินิจฉัยว่าคนไข้มีประสิทธิภาพในการนอนมากน้อยเพียงใด

\Rightarrow โดยใช้ ตัวชี้วัดที่เรียกว่า Sleep efficiency

\Rightarrow สัญญาณที่หมอเก็บขณะคนไข้นอน คือ Polysomnogram : EEG (สมอง), EOG(จอตาล), ECG(ใจ), EMG(เคลื่อนไหวของกล้ามเนื้อ เช่น การกัดฟัน)

พอได้ ก็เอามาดูว่าคนไข้หลับอยู่ใน stage ใดแล้ว แต่กระบวนการนี้ใช้เวลาเยอะ เพราะคนไข้หลับหลายคืน แต่ละคืนก็มีสัญญาณที่ต้องทำการวิเคราะห์ 6-8 ชม.

\rightarrow หมอแบ่งคลื่นสัญญาณออกเป็นช่วงละ 30 วินาที ดังนั้นใน 1 ชม. จะมีสัญญาณหลายอัน 2 กลุ่มหลักที่เกี่ยวข้องกับการนอน

- ☐ Non-Rapid eye movement \Rightarrow คนไข้ไม่มีการขยับลุกตา
 - N1 - sleep onset \Rightarrow จุดเริ่มต้นของการนอนหลับ
 - N2 - light sleep \Rightarrow หลับตื้น
 - N3 - Deep sleep \Rightarrow หลับลึก


- ☐ Rapid eye movement (REM) → Dream ส่วนใหญ่ ⇒ **จริงๆ นอนแล้วฝัน มีประโยชน์ช่วยเสริมสร้างความคิดสร้างสรรค์**

→ Normal pattern จะมีการเปลี่ยนสภาวะการนอนไปมาระหว่าง non-REM และ REM หลายครั้ง / 1 คืน


- ☐ Awake (W)

ปัญหาในการวิเคราะห์การนอน ⇒ โจทย์ multi-class classification in ML

สัญญาณลักษณะต่างๆ



Pattern K complex ⇒ ถ้าคลื่น ... M1 วัดได้จากสมอง ในช่วงเวลา 30 วินาที คือ light stage และจะมี sleep spindle fh;p



คลื่นสัญญาณระหว่างที่ฝัน ⇒ สัญญาณจากจอตา LOC, ROC จะมีคลื่นไฟฟ้าสูงมาก คลื่นสมองค่อนข้าง stable เป็น low voltage ***ซึ่งจากรูป ใช้คลื่นสมองทั้งหมด 3 channel อาจจะต้องใช้อัลกอริทึมรูปแบบอื่น***

ตัววินิจฉัยว่าหลับมีประสิทธิภาพแค่ไหน

1. Total sleep time (TST) ⇒ จำนวนนาฬิกาที่เราหลับ มีกี่นาฬิกาต่อแต่ละสแตจ (N1 + N2 + N3 + REM)
2. Time in bed (TIB) ⇒ เวลาที่เราเก็บสัญญาณทั้งหมด (ไฟดับ — ไฟเปิด)
3. Sleep efficiency (%) ⇒ $(TST/TIB) \times 100\%$ ยิ่งน้อยยิ่งมีปัญหาในการนอน

ปัญหา

⇒ คนไข้มีมาก ปริมาณเตียงและหมอนผู้ป่วยมีน้อย

⇒ อุปกรณ์ในการเก็บสัญญาณมีเยอะมาก ทำให้ไม่สามารถเอากลับไปใช้ที่บ้านได้ อุปกรณ์แพง ติดตั้งยาก สัญญาณอาจไม่มีคุณภาพหากติดตั้งเอง

วิธีแก้ที่วิจัยในปัจจุบัน

⇒ ใช้เฉพาะคลื่นสัญญาณคลื่นเดียว single-channel EEG ⇒ DL model เรียนรู้เพื่อวิเคราะห์การนอนของคนไข้ ⇒ สร้างอุปกรณ์พกพาสะดวก เช่น in-ear ERG, ผ้าคาดหัวมี electrode สำหรับวัดคลื่นสมอง

[Public Sleep Dataset](#) ⇒ ชื่อ SleepEDF (v.1)

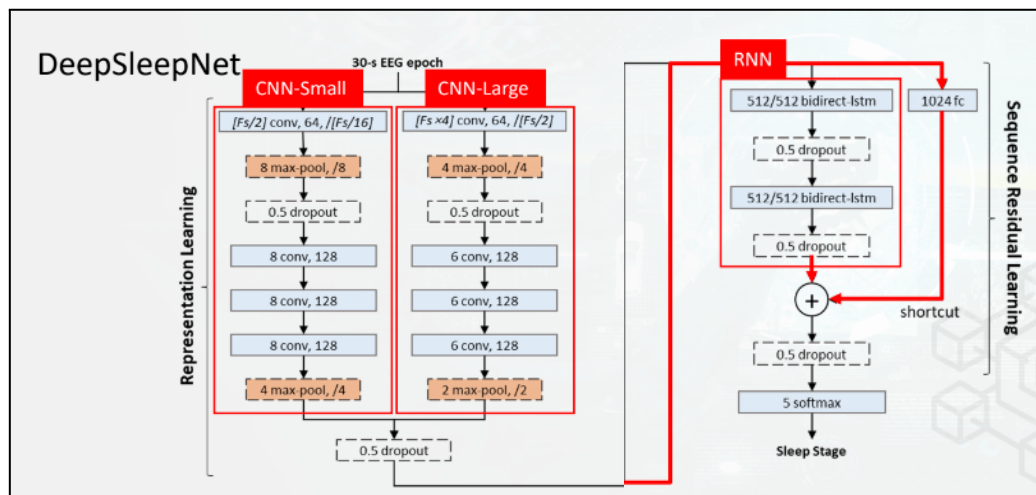
⇒ ข้อมูลคนไข้ 20 คน (age 28.7 ± 2.9)

⇒ signal: มีหลายอย่างมาก แต่เราใช้แค่ คลื่นสมอง (EEG) และสเตรจของคนไข้เลย แต่จะมี MOVEMENT, UNKNOWN ที่เป็น noise ต้องลบออก

⇒ signal files: *-PSG.edf

⇒ Hypnogram files: *-Hypnogram.edf

Model

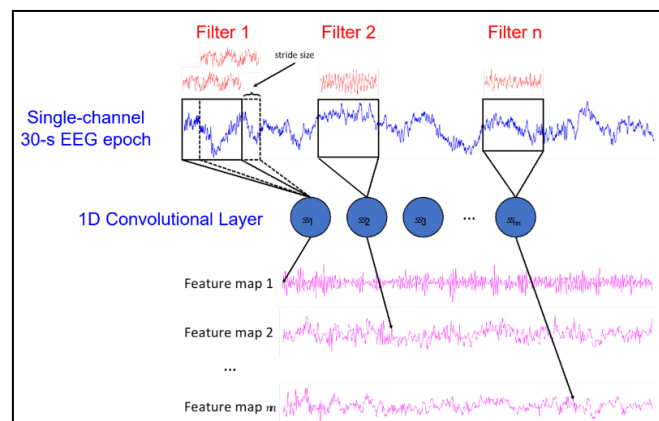


- DeepSleepNet ⇒ แบบจำลองที่ถูกออกแบบมาเพื่อวิเคราะห์การนอนโดยรับคลื่นสัญญาณสมองแบบ single-channel EEG พยายามที่จะตัดสัญญาณอื่นๆออก เพื่อให้ง่ายต่อการนำไปใช้งาน สามารถพกพา ไปวัดและวิเคราะห์การนอน ขณะที่คนไข้ไม่ได้อยู่ที่รพ. ประกอบด้วย 2 ส่วนหลัก

DeepSleepNet จะรับ input 30 seconds คลื่นสัญญาณสมอง single channel เข้าสู่ Representation Learning 2 แขนงที่เป็น 1D CNN จากนั้นจะมารวมกันตอนท้าย แล้วส่งต่อไปยัง component Sequence Residual Learning แล้วก็จะได้ผลลัพธ์ออกมาเป็น 1 ใน Sleep Stage ⇒ คนไข้หลับอยู่ใน sleep stage ใหนนั่นเอง

แบ่งแขนงเป็น CNN-Small และ CNN-Large เพราะกระบวนการวิเคราะห์สัญญาณต่างๆไปเคาะทำมีหน้าที่สำหรับสกัดคุณลักษณะเด่นในคนละความถี่ ถ้าอยากใช้ฟิลเตอร์ที่มีความถี่เพื่อสกัดเอาคุณลักษณะเด่นในคลื่นความถี่สูง จะต้องใช้ฟิลเตอร์ที่มีขนาดเล็ก (CNN-Small) มีระยะสั้น และหากต้องการสกัดเอาคุณลักษณะเด่นในคลื่นความถี่ต่ำ จะต้องใช้ฟิลเตอร์ที่มีขนาดใหญ่ มีระยะยาว (CNN-Large)

CNN จะเรียนรู้ด้วยตัวเองว่าต้อง detect คลื่นสัญญาณรูปแบบใดบ้าง โมเดลจะมีความสามารถในการเรียนรู้และรับให้เข้ากับคนไข้แต่ละคนได้



→ การทำงานภายใน CNN แต่ละตัวจะมี 1D convolutional layer จะมี neurons อยู่หลายตัว ในแต่ละนิวรอน จะเป็น 1 filter ความกว้างของแต่ละนิวรอน จะเป็น filter size สมมติมีคลื่นสัญญาณ 1 เส้น 30 s convolutional ก็ทำการเรียนรู้ pattern ในแต่ละ filter ในทุกครั้งที่สแกน ก็จะได้ผลลัพธ์ออกมา 1 ตัว

→ convolutional 1D จะพยายามหา filter ที่มี pattern แตกต่างกันไป เป้าหมายคือ มีแพทเทิร์นไหนที่เกิดขึ้นในช่วงเวลา 30 s บ้าง

→ หลังจากนั้นค่อยมาเรียนรู้ว่า คลื่นนี้อยู่ในสภาวะการนอนแบบใด

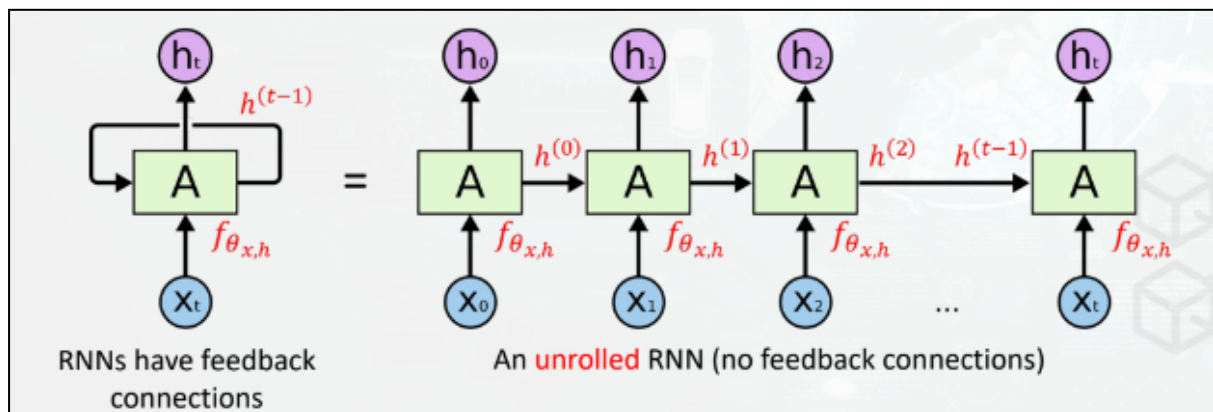
อีกส่วนหนึ่งคือ RNN ⇒ Recurrent Neural Network นิยมใช้ในการเรียนรู้ sequence

⇒ ผู้เชี่ยวชาญมีคู่มือ บอกกฎในการเปลี่ยนสภาวะ **stage transition rules** ต้องการให้ RNN เรียนรู้โดยไมใช้กฎนี้

-AASM manual ที่ใช้ในวิจัยนี้ เช่น ถ้าคนไข้อยู่ใน N2 → continue to score N2 แม้ว่า K complex หรือ sleep spindle หายไปแล้ว

⇒ 30s ของสภาวะที่เห็นอยู่จบ. ต้องอาศัย sleep stage ก่อนหน้าที่เค้า label ด้วยควบคู่กันไป

ซึ่ง CNN ไม่สามารถเรียนรู้ได้ แต่ RNN ทำได้



เพิ่ม shortcut connection เข้ามาด้วย เสมือนว่าให้โมเดลเลือกได้ว่าจะเรียนรู้คุณลักษณะ มากน้อยเพียงใด

DeepSleepNet

⇒ ใช้ Cross-entropy loss ซึ่งมักใช้กับ image learning

⇒ Adam Optimize parameter

⇒ แบบจำลองจำเป็นการหา θ ที่จะทำให้ผลรวมบน training set มีค่าน้อยที่สุด ⇒ pattern ที่ดีที่สุด

⇒ สิ่งทีโมเดลทำนาย ตรงกับค่าจริง loss ตัวนี้จะเป็น 0 ถ้าไม่ตรงกัน loss มากกว่า 0

DeepSleepNet

- Cross-entropy loss
- Adam optimizer
- f_θ is the DeepSleepNet
- $x^{(i)}$ is a 30-s EEG epoch
- $y^{(i)}$ is a sleep stage label

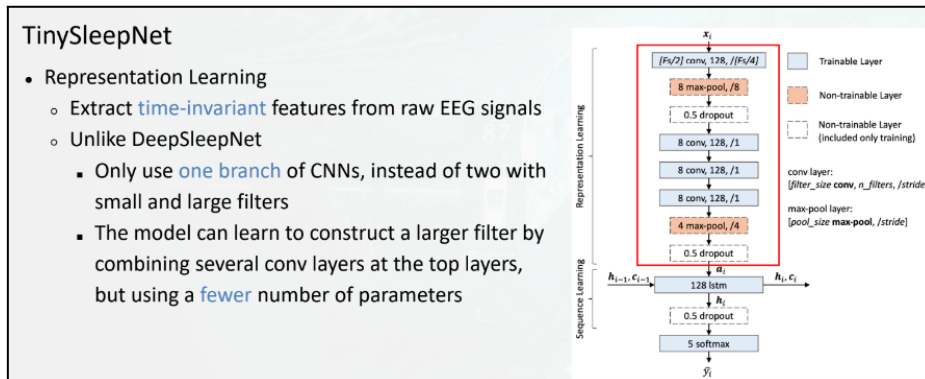
$$\theta^* = \arg \min_{\theta} J(\theta) = \arg \min_{\theta} \frac{1}{m} \sum_{i=1}^m L(f_\theta(x^{(i)}), y^{(i)})$$

Tiny SleepNet ⇒ ต่อยอดมาจาก DeepSleepNet

⇒ เพราะ DeepSleepNet มีขนาดใหญ่ เอาไปติดตั้งบนอุปกรณ์พกพายาก วิจัยจึงคิดค้นโมเดลนี้ขึ้น ลดจำนวนเลเยอร์

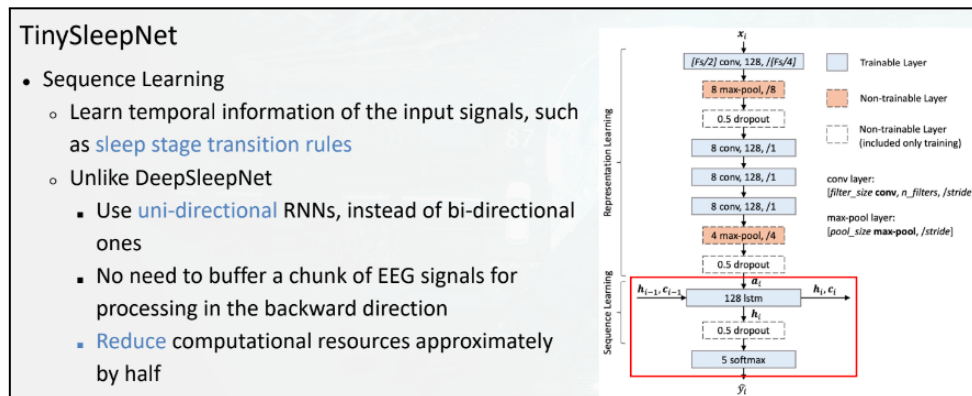
☐ Representation Learning

⇒ ใช้ 1D CNN ที่มีขนาดเล็กลง เพราะตัดแขนงทิ้งออกไป

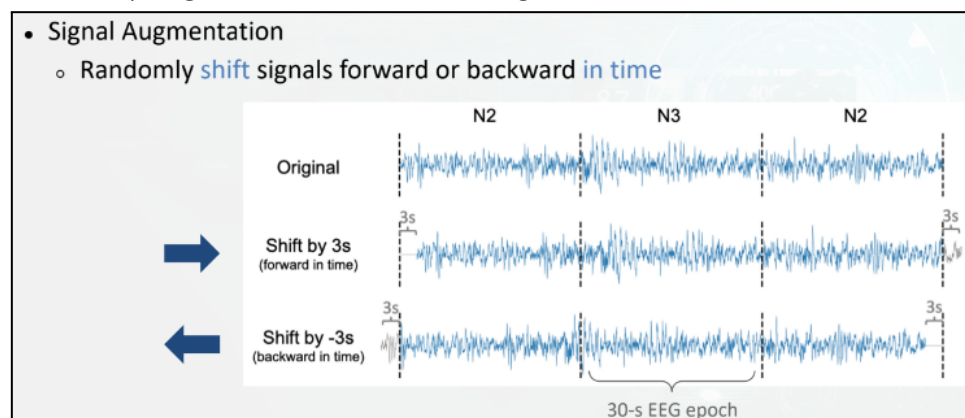


☐ Sequence Learning

⇒ ใช้ RNN เหมือนเดิมแต่ลดเหลือ layer เดียว



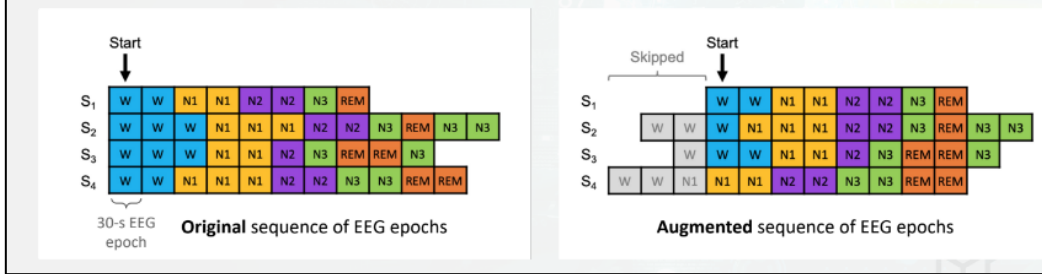
- Data augmentation: สร้าง training set โดยอาศัย
 - signal augmentation ⇒ การ shift ข้างหน้า/หลัง เล็กน้อย ทำให้โมเดลเรียนรู้ได้ดีขึ้นในการทำนาย sleep stage ช่วยเพิ่ม variation โดยใช้ range 0-3 s



- Sequence augmentation ⇒ สุ่มว่าจะเริ่มตามเดิมทุกครั้ง หรือข้ามไปบ้างเพื่อให้เรียนรู้ได้หลากหลายมากขึ้น เช่นรูป 2 S1 ไม่ข้ามเลย, S2 ข้าม 2 stage, S3 ถูกข้ามไป 1, S4 ถูกข้ามไป 3
- นี่เป็นเทคนิคที่ช่วยเพิ่มให้ข้อมูลคนไข้มีความหลากหลายมากขึ้น

Sequence Augmentation

- A few EEG epochs at the beginning of each sleep sequence are **skipped by a random amount**



- Weight Cross-entropy loss \Rightarrow ช่วยให้โมเดล ไม่ overfit เช่น เวลาคนนอน N1 จะมีปริมาณน้อยกว่า N2 และ N3 \rightarrow ลงโทษโมเดลที่ทาย N1 ผิดมากกว่าที่ทาย N2/N3 เพราะคนส่วนใหญ่ต้องมี N1 น้อยอยู่แล้ว จะทำให้โมเดลทำงานได้ถูกต้องมากขึ้นบนสแตต N1
- ครอบคลุมการเทรนทั้งหมด No-pre training

Evaluation

\Rightarrow k-fold cross validation (non-overlapping point split) เวลาแบ่งข้อมูลจะไม่มีคนใช้คนเดียวกันอยู่ในทุกเซต


หมายความว่า คนใช้ คน อยู่ได้แค่ training set ไม่ก็ validation set หรือ test set

\Rightarrow Metrics


- \rightarrow Overall: ACC, MF1, $\kappa \Rightarrow$ วัดผลของ sleep stage ทั้ง 5 แบบสรุปภาพรวม
- \rightarrow Per-Class: Precision, Recall, F1-score

\Rightarrow Visualization

- \rightarrow Hypnogram: แกน x เป็นเวลา y เป็น stages of sleep




		ACTUAL	
		P	N
PREDICTED	P	A patient has cancer and predict cancer.	A patient does not have cancer, but predict cancer.
	N	A patient has cancer, but predict no cancer.	A patient does not have cancer, and predict not cancer.



☐ Model Evaluation: TinySleepNet ทำงานได้ดีที่สุดเมื่อเทียบกับอัลกอริทึมอื่น และยังสามารถปรับ data set อื่น

Achieve a <i>similar (if not better)</i> performance compared to the state-of-the-art methods on all datasets															
Methods	Datasets	Manual	EEG Channels	F ₁ (Hz)	Epoch (sec)	k-fold CV	Test Epochs	Overall Metrics	Per-class F1-Score (F1)						
								ACC	MPFI	ϵ	W	N1	N2	N3	REM
ITNet [6]	Sleep-EDF-v1	R&K	Fpz-Cz	100	30	20	42308	84.0 77.7 0.78	87.9	44.7	88.0	85.7	82.1		
SegSleepNet+ (FT) [9]	Sleep-EDF-v1	R&K	Fpz-Cz	100	30	20	-	85.2 79.6 0.79	-	-	-	-	-	-	-
DeepSleepNet [7]	Sleep-EDF-v1	R&K	Fpz-Cz	100	30	20	42308	84.3 79.7 0.79	89.2	52.2	86.8	85.1	85.1		
DeepSleepNet [5]	Sleep-EDF-v1	R&K	Fpz-Cz	100	30	20	41950	82.0 76.9 0.76	84.7	46.6	85.9	84.8	82.4		
Our method	Sleep-EDF-v1	R&K	Fpz-Cz	100	30	20	44220	85.4 80.5 0.80	90.1	51.4	88.5	88.3	85.1		
DeepSleepNet [7]	Sleep-EDF	R&K	Fpz-Cz	100	30	10	195479	80.0 73.6 0.74	91.7	44.1	82.5	73.5			
Our method	Sleep-EDF	R&K	Fpz-Cz	100	30	10	199155	83.1 78.1 0.77	92.8	51.0	85.3	81.1			
Our method	MASS-SS1	AASM	F4-EOG (L)	256	30	27	51293	83.1 79.3 0.76	90.0	60.6	87.4	73.2	81.5		
Our method	MASS-SS2	R&K	F4-EOG (L)	256	30	19	26711	82.6 75.5 0.75	76.6	48.2	87.8	80.5			
ITNet [6]	MASS-SS3	AASM	F4-EOG (L)	256	30	31	57995	86.5 80.8 0.80	86.1	54.4	91.3	86.0			
DeepSleepNet [5]	MASS-SS3	AASM	F4-EOG (L)	256	30	31	58600	86.2 81.7 0.80	87.3	59.8	90.3	81.5	89.3		
Our method	MASS-SS3	AASM	F4-EOG (L)	256	30	31	59317	87.5 83.2 0.82	87.3	62.7	91.8	85.5			
Our method	MASS-SS4	R&K	C4-EOG (L)	256	20	20	55310	84.0 78.0 0.77	79.8	50.2	88.9	82.4	85.5		
Our method	MASS-SS5	R&K	F4-EOG (L)	256	20	26	36409	86.6 80.9 0.81	85.5	55.0	89.9	86.6	87.7		



\rightarrow NO sacrificing the performance on any sleep stage, especially N1 (most difficult sleep stage to classify)

Future Work

Conclusions

\Rightarrow DL จะสามารถ applied on biosignal ก็ควรมีคุณหมอมหรือผู้เชี่ยวชาญยืนยันอยู่ดี

\Rightarrow การใช้ spectrogram ที่จะสามารถ transform raw signals into image-based

- can use CNN that process images
- แต่ก็ยังไม่ดีมากเท่าไร จากหลายงานวิจัยเพราะมันยังต้องผ่านกระบวนการอยู่ ใช้ DL ดีกว่า

\Rightarrow สามารถต่อยอดโมเดลนี้ได้ โดยเอาไปติดตั้งบน smart device / transfer learning technique มาใช้งานกับโมเดลได้

\Rightarrow early stages or sign for harmful disease he'p both doctors and patient