### Class 4: Mental disorder detection from social media data

#### **ProblemStatement**

- การพัฒนาโมเดลเพื่อทำนายคนที่มีโรคซึมเศร้าจากข้อมูลในสื่อออนไลน์ มีความสำคัญ เพราะโดยปกติคนที่มีภาวะซึม เศร้า เครียด มักจะหาสถานที่หรือที่ใช้ในการสื่อถึงความรู้สึกของเค้าให้คนอื่นรับรู้ โดยปัจจุบัน คนมักใช้สื่อสังคมออน ไลน์ในการนำเสนอความรู้สึก ความคิดต่างๆ ในสิ่งที่เค้าได้ทำ ซึ่งข้อมูลเหล่านี้มีอยู่มากบนแพลตฟอร์มสื่อสังคมออ นไลน์
- → เราสามารถสังเกตได้ว่า แต่ละวันโพสต์ข้อความ รปภาพ วิดีโอไปเท่าไหร่ หรือการแชทคยกับเพื่อน ⇒ Media Data
- → สามารถพัฒนา Al เพื่อให้เข้าใจพฤติกรรม อารมณ์ของคน จากการสื่อสารบนสังคมออนไลน์
- ⇒ นำไปสู่การช่วยเหลือดนที่มีภาวะซึมเศร้า เครียด ภาวะสุขภาพ
- ⇒ Social Media : เป็นแพลตฟอร์มบนสังคมออนไลน์ที่ให้คนสามารถมา create, discuss, modify, and exchange content

สามารถสร้างตัวตน หรืออัตลักษณ์ของเราได้ establish or maintain relationships

- ⇒ นักวิจัยให้ความสำคัญกับสื่อสังคมออนไลน์ เพราะมีผู้ใช้งานเยอะ สามารถเข้าถึงได้แบบทันที รวดเร็ว ความคิดเห็นอิสระ Data Collection
  - การเก็บข้อมูลจากสื่อ นำมาสร้างโมเดลทำนายแยกคนที่มี / ไม่มี ภาวะซึมเศร้า
  - Types of Social Media
- → Forums : online discussion board **กระหู**ในการแลกเปลี่ยนความเห็น หรือสอบถามข้อมูล เช่น pantip
- → Microblogs : **users diary** ใช้โพสต์ข้อความ รูป วิดีโอ ลิงก์ มี follower เช่น x , weibo
- → Products / services review : provide **product info** เช่น lazada shoppee
- → Social Network : platform allow **user to connect to others**, know each other, have common interest เช่น fb
- ightarrow Photo / Video sharing : upload caption , share photo เช่น ig, youtube

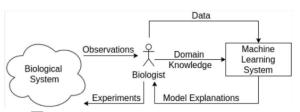
# ■ Social Media Matrix

	Customised Message	Broadcast Message	
_	Relationship	Self-Media	
ased	Allowing users to connect, reconnect,	Allowing users to broadcast their updates	
Profile-based	communicate, and build relationships.	and others to follow.	
	(e.g., Facebook, LinkedIn)	(e.g., Twitter, Weibo)	
ased	Collaboration	Creative outlets	
	Allowing users to collaboratively find	Allowing users to share their interest,	
Content-based	answers, advice, help, and reach consensus.	creativity, and hobbies with each other.	
	(e.g., Quora, Reddit, Yahoo! Answers)	(e.g., YouTube, Flickr, Pinterest)	

- Data collection : เก็บข้อมูล 2 ส่วนหลัก ๆ คือ ข้อมูลคน และ ข้อมูลสื่อสังคมออนไลน์
- → ข้อมูลคน ⇒ เก็บโดยตรงจากผู้ร่วมวิจัย, aggregate and extract from public post, available dataset
  - ⇒ เก็บจากผู้ร่วมวิจัยโดยใช้การทำแบบสอบถาม / Electronic Helth Record ⇒ label
  - ⇒ aggregate by searching ⇒ Annotate

# **Data Exploration & Preprocessing**

## ■ Domain knowledge

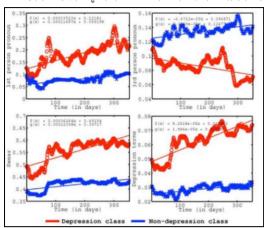


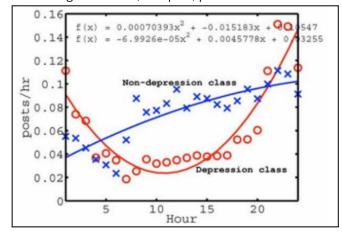
# **Symptoms of Depression**

- Lost interest in doing thing, appetite
- Seems hopeless
- Slower movements
- Tired no energy
- Has trouble concentrating
- Sleeping more or unable to sleep

### ☐ Feature Extraction

- → ใช้การสกัดคำ เช่น CountVecterize จะเป็นหนึ่งใน package สำหรับการนับคำ ตัดคำเชื่อมออกและแปลงเป็น array
- → LIWC ใช้สกัดประโยค : ทางการใหม, นับคำ, pronounce article, number, positive, negative
- → visualize : มาดูความแตกต่างของคนที่มี / ไม่มีภาวะซึมเศร้า ใช้ negative words, less post, pronounce





**Predictive Models** 

# ■ NLP with Supervised Learning

Unset

$$\label{eq:cost_function} \begin{split} \text{Input} \Rightarrow \text{Feature extractor} \Rightarrow \text{Features} \ \Rightarrow \text{Supervised ML} \ \Rightarrow \text{output} \\ \text{Label} \ \Rightarrow \ \text{Cost function} \ & \\ \hline & \\ \end{split}$$

- $\rightarrow$  word count , Positive / Negative words
- $\to \mathsf{ML}$

#### **Evaluation**

	precision	recall	acc. (+ve)	acc. (mean)
engagement	0.542	0.439	53.212%	55.328%
ego-network	0.627	0.495	58.375%	61.246%
emotion	0.642	0.523	61.249%	64.325%
linguist. style	0.683	0.576	65.124%	68.415%
dep. language	0.655	0.592	66.256%	69.244%
demographics	0.452	0.406	47.914%	51.323%
all features	0.705	0.614	68.247%	71.209%
dim. reduced	0.742	0.629	70.351%	72,384%

Table 6. Performance metrics in depression prediction in posts using various models. Third column shows the mean accuracy of predicting the positive class.

- → โมเดลทำนายคนที่เป็น/ไม่เป็นซึมเศร้าถูกต้อง 72.38%
- → ทำนาย feature เช่น engagement, ego-net, dep lang
- → การลดจน.feature (dim reduced) ทำให้โมเดลทำงานได้ดีขึ้น เพราะบางทีบางตัวแปรมันขัดแย้งกัน
- → เทียบข้อมูลบางช่วงเวลา บางโมเดลก็อาจจะดีกว่า

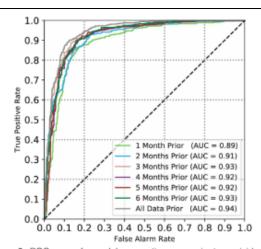


Figure 6. ROC curves for models separating users prior to a suicide attempt from their matched controls. The green line only uses data for the month prior to the suicide attempt to make the classification (30 to 0 days prior), the blue line uses data from 2 months prior (60 to 0 days prior), and so on. The black line indicates performance using all of the data available for that user prior to their attempt. ROC indicates receiver operating characteristic.